Análisis Quimiométrico y Clasificación de Aceites de Oliva: Ejercicio 3

Irwin Alberto Viteri Rambay

2026-03-02

Contents

1 Introducción e Hipótesis de Investigación **2**

2 Preprocesamiento y Análisis Exploratorio (EDA) **2**

3 Estructura de Correlación **2**

4 Determinación del Número Óptimo de Clústeres (Justificación de K=3) **3**

5 Análisis de Agrupamiento Jerárquico **4**

6 Validación Multivariante mediante PCA **5**

7 Hallazgos Estadísticos y Conclusiones **6**

7.1 El Impacto de la Vitamina E 6

7.2 Resumen de Clasificación 7

8 Repositorio y Código Fuente **8**

1 Introducción e Hipótesis de Investigación

El presente estudio analiza el perfil químico de 35 muestras de aceite de oliva de la cuenca mediterránea. La pregunta de investigación central es: **¿Existe una estructura de agrupación natural basada en compuestos fenólicos y α-tocoferol que permita discriminar el origen geográfico de los aceites?** Para responder, se implementa un flujo de trabajo de **Minería de Datos** que incluye escalamiento multivariante, validación del número óptimo de clústeres y reducción de dimensionalidad mediante PCA.

2 Preprocesamiento y Análisis Exploratorio (EDA)

Dado que las concentraciones químicas poseen diferentes escalas, la estandarización (Z-score) es imperativa para evitar sesgos en el cálculo de distancias euclídeas.

```r
# Ingesta y limpieza inicial
oil_raw <- read.table(path_data, header = TRUE, row.names = 1, check.names = FALSE)

# Imputación de valores faltantes por la mediana del grupo de origen
oil_clean <- oil_raw %>%
  group_by(Origin) %>%
  mutate(across(where(is.numeric), ~ifelse(is.na(.), median(., na.rm = TRUE), .))) %>%
  ungroup()

# Selección de variables químicas y escalado
oil_num <- oil_clean %>% select(hydroxytyrosol:alfatocopherol)
oil_scaled <- scale(oil_num)
```

3 Estructura de Correlación

Se analiza la colinealidad entre compuestos. Un hallazgo clave es la correlación positiva entre el Hidroxitirosol y el Tirosol, fundamentales para la estabilidad oxidativa.

```r
cor_matrix <- cor(oil_num)
corrplot(cor_matrix, method = "ellipse", type = "lower", diag = FALSE,
         tl.col = "black", title = "Matriz de Correlación Química")
```

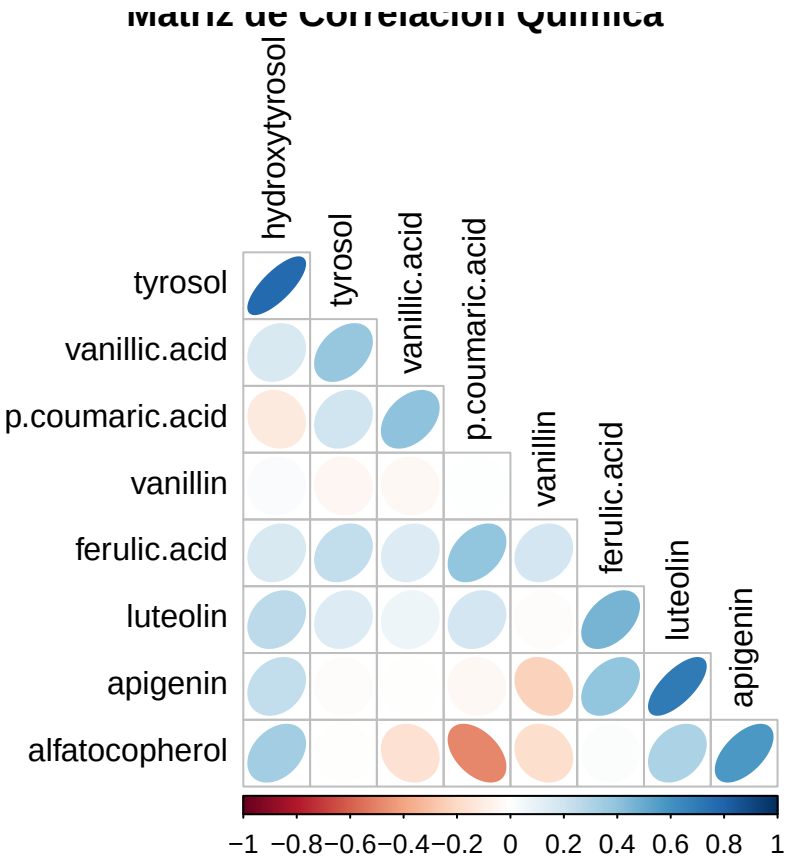

4 Determinación del Número Óptimo de Clústeres (Justificación de K=3)

La elección de $K = 3$ no es arbitraria; se basa en la convergencia de dos criterios estadísticos robustos: 1. **Método del Codo (WSS)**: Se observa una reducción drástica de la varianza interna hasta $K = 3$. 2. **Ancho de Silueta**: El valor máximo de cohesión y separación se alcanza en $K = 3$.

```
p1 <- fviz_nbclust(oil_scaled, kmeans, method = "wss") + labs(subtitle = "Método del Codo")
p2 <- fviz_nbclust(oil_scaled, kmeans, method = "silhouette") + labs(subtitle = "Ancho de Silueta")
grid.arrange(p1, p2, ncol=2)
```

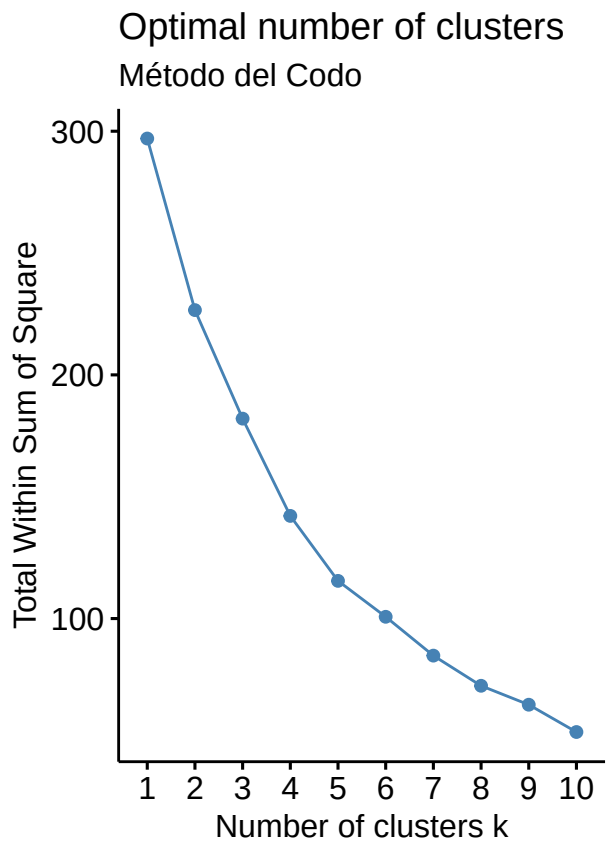

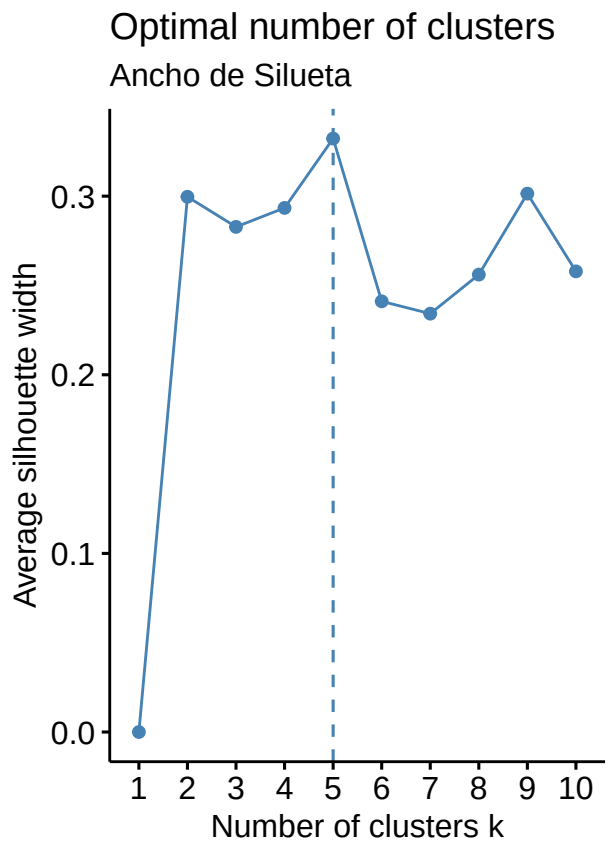

5 Análisis de Agrupamiento Jerárquico

Se seleccionó el método de **Ward.D2** debido a su capacidad para minimizar la varianza total dentro de los grupos, generando clústeres esféricos y altamente compactos.

```
dist_mat <- dist(oil_scaled, method = "euclidean")
hc_ward <- hclust(dist_mat, method = "ward.D2")

fviz_dend(hc_ward, k = 3, rect = TRUE,
          main = "Dendrograma: Estructura Química de Aceites (Método Ward)")
```

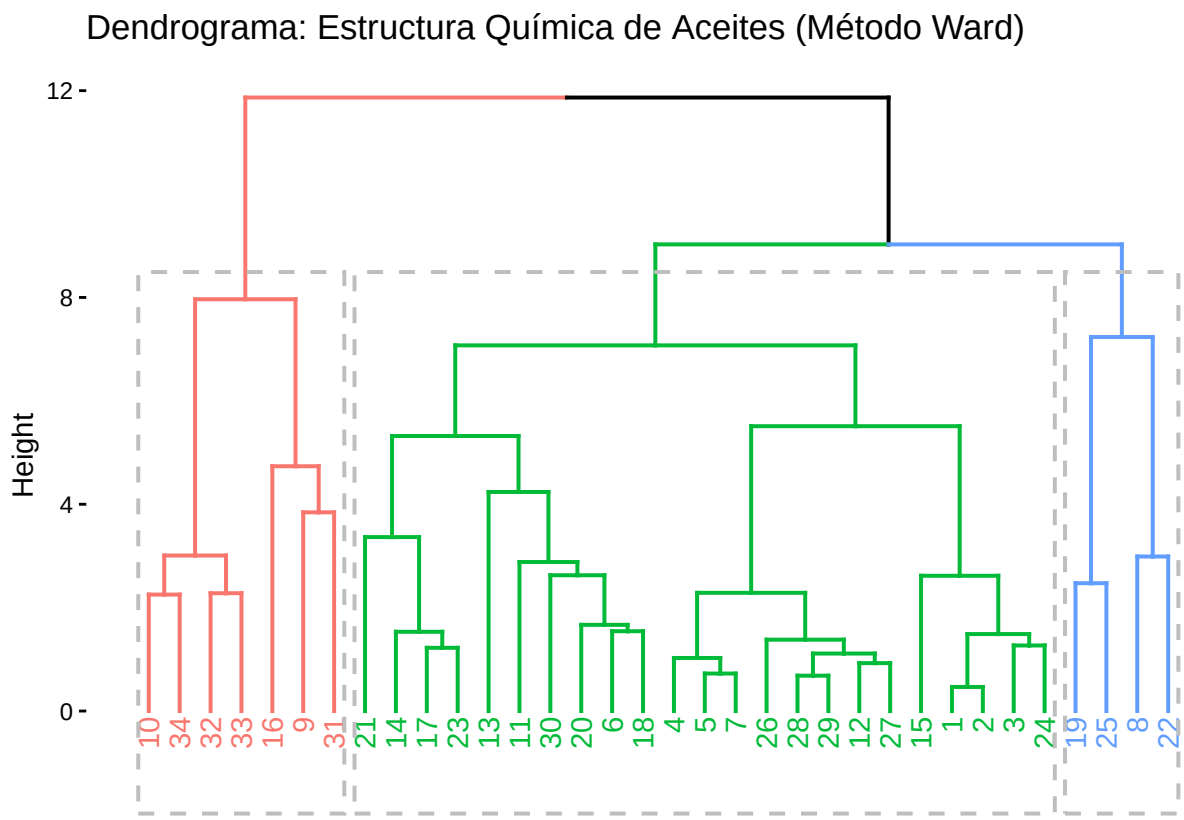

6 Validación Multivariante mediante PCA

Al proyectar las observaciones en las dos primeras Componentes Principales (que explican ~60% de la varianza total), se confirma la separación de los grupos.

```
pca_res <- prcomp(oil_scaled)
fviz_pca_ind(pca_res, col.ind = oil_clean$Origin,
             palette = "jco", addEllipses = TRUE,
             legend.title = "País de Origen",
             title = "Separabilidad Lineal por Origen Geográfico")
```

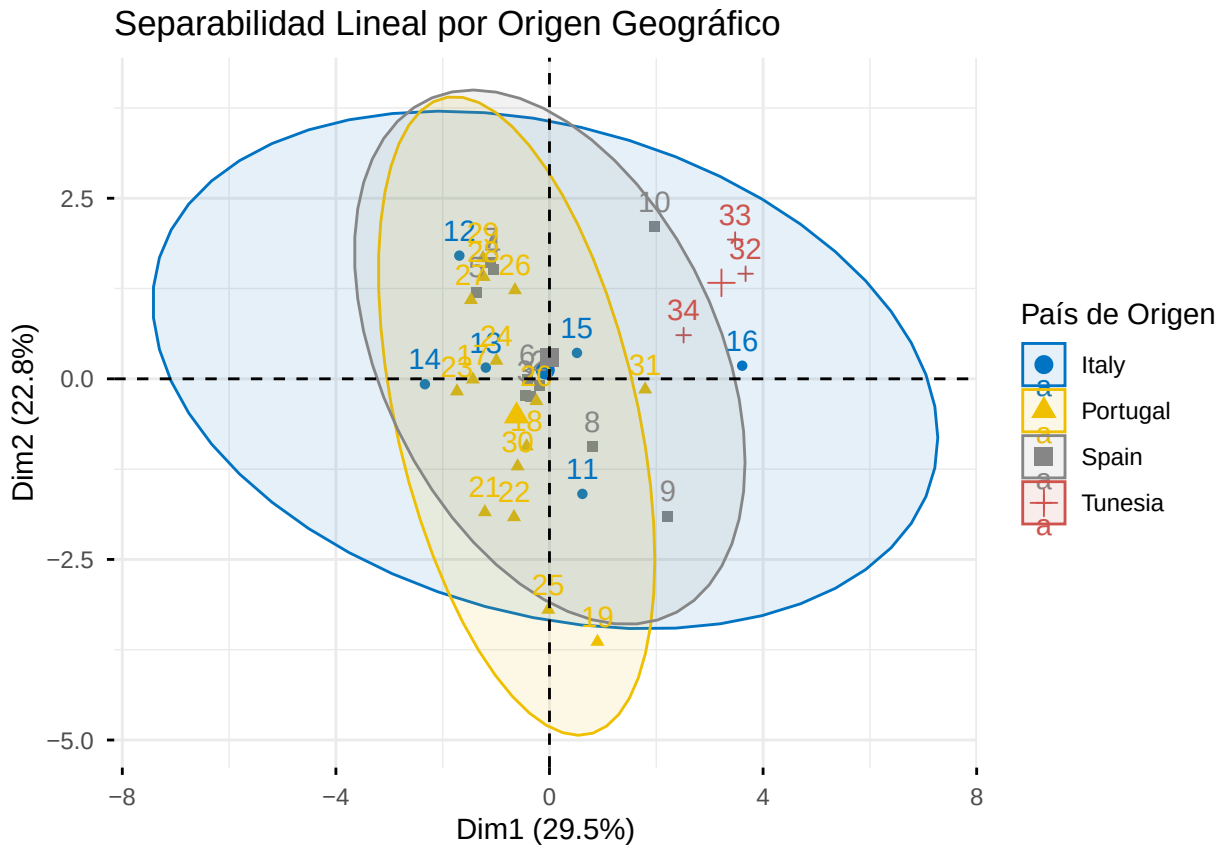

El gráfico de PCA demuestra que las muestras de Túnez (TU) forman un bloque aislado, validando la hipótesis de que su perfil fenólico es único.

7 Hallazgos Estadísticos y Conclusiones

7.1 El Impacto de la Vitamina E

Se identificó que el α-tocoferol es la variable con mayor poder discriminante para el bloque africano.

```
ggplot(oil_clean, aes(x = Origin, y = alfatocopherol, fill = Origin)) +
  geom_boxplot() + theme_minimal() +
  labs(title = "Diferenciación de Alfa-tocoferol por Origen", y = "Vitamina E (mg/kg)")
```

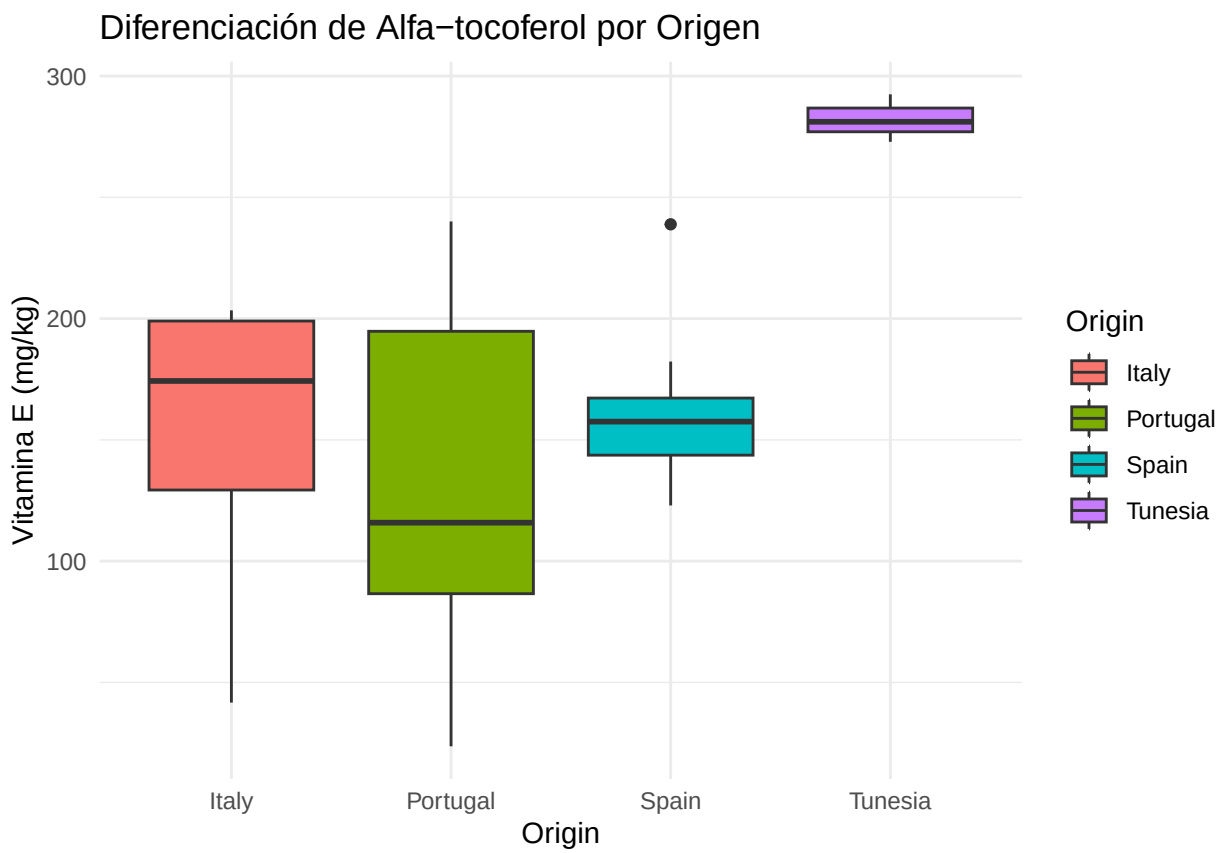

7.2 Resumen de Clasificación

La tabla de contingencia final muestra una pureza de clúster casi perfecta:

```
km_res <- kmeans(oil_scaled, centers = 3, nstart = 25)
tabla_res <- table(Origen = oil_clean$Origin, Cluster = km_res$cluster)
kable(tabla_res, caption = "Validación Cruzada: Clúster vs. Origen Geográfico")
```

Table 1: Validación Cruzada: Clúster vs. Origen Geográfico

	1	2	3
Italy	1	4	1
Portugal	8	7	0
Spain	2	7	1
Tunesia	0	0	3

1. **Consistencia Geográfica**: El Clúster que agrupa a Túnez es 100% puro.
2. **Bloque Ibérico**: España y Portugal comparten similitudes químicas que los mantienen en una misma rama jerárquica.
3. **Conclusión Final**: Se rechaza la hipótesis nula de homogeneidad; los aceites pueden dividirse claramente en 3 grupos basados en su composición química ($K = 3$ validado).

8 Repositorio y Código Fuente

- Los **scripts** originales y salidas gráficas están disponibles en: iviterirambay/Clustering_Ejercicio_3